

文章编号: 1009-6094(2021)01-0277-08

基于 ARIMA 和 XGBoost 组合模型的交通事故预测

谢学斌, 孔令燕

(中南大学资源与安全工程学院, 长沙 410083)

摘要: 近年来交通事故及其损失严重影响社会经济的发展 and 人民生活水平的提高, 交通事故预测可以为交通事故预防提供数据支持。基于自回归滑动平均(ARIMA)模型和极端梯度提升(XGBoost)模型, 构建时间序列组合预测模型, 对交通事故相关指标进行趋势预测。根据交通事故的特点, 选定“事故起数”“受伤人数”“死亡人数”及“损失”4个指标。首先, 根据自相关、偏自相关图确定 ARIMA 模型参数, 根据 AIC (赤池信息准则) 值确定最终模型; 然后, 对4个指标的 ARIMA 模型预测结果的残差构建残差序列, 对其进行 XGBoost 建模, 得出修正后的残差预测值; 最后, 根据残差预测值和 ARIMA 模型预测值得出组合模型最终的预测值。实例结果表明, 4项指标的混合预测模型的预测精度均优于单一的 ARIMA 模型和 Holt-Winters 模型, 其中以“受伤人数”和“死亡人数”的模型改善效果最为显著, “受伤人数”指标的平均绝对百分比误差降低了 5.431 7 个百分点, “死亡人数”指标的平均绝对百分比误差降低了 3.625 9 个百分点。

关键词: 安全工程; 交通事故预测; 时间序列; ARIMA; XGBoost

中图分类号: X92 文献标志码: A
DOI: 10.13637/j.issn.1009-6094.2019.0633

0 引言

道路交通事故相关指标预测是指在事故资料统计、分析和挖掘的基础上, 对事故变化规律进行研究, 对事故发展趋势进行预测。常用的预测方法有统计回归法、时间序列法、马尔科夫链法、灰色预测法、神经网络法及其他非线性预测方法等。其中, 交通事故时间序列预测模型是基于时间序列分析理论, 在统计、分析和挖掘事故资料的基础上, 研究事故变化规律、探究事故特征趋势的一种模型。因此, 交通事故预测研究是预防道路交通事故发生的基础性工作, 也为分析交通事故变化规律、提高预测精度提供理论依据。交通事故作为一种随机事件, 其产生和变化机理受各种客观因素影响, 其趋势特征不

全属于随机性质, 数据中既包含线性关系又包含非线性关系, 很大程度上影响了经典时间序列模型的预测效果。

ARIMA 是一种对时间序列进行预测的重要方法。1979 年, Jakobsson^[1] 首次利用 ARIMA 模型对北半球 50 kPa 高度进行了长距离预测, 从而预测了北半球的大气环流模式。李榕^[2] 提出运用 ARIMA 模型预测我国工伤事故死亡率, 结果表明该模型更适合于短期预测。2012 年, 甘旭升等^[3] 提出了一种时序的差分自回归滑动平均(ARIMA)模型, 首次用来预测美国空军飞行事故万时率, 结果总体反映了航空装备的实际安全状况。2014 年, 孙轶轩等^[4] 开创性地提出基于自回归滑动平均(ARIMA)模型和支持向量回归机(SVR)模型来预测交通事故, 结果表明, 该时间序列组合预测模型精度优于单一 ARIMA 模型。2017 年, Xu 等^[5] 第一次提出了一种基于 ARIMA 模型和 Kalman 滤波算法的道路交通流预测方法, 试验表明, 该实时道路交通状态预测方法是可行的。Eymen 等^[6] 使用 ARIMA 模型对亚穆拉大坝的平均相对湿度时间序列进行建模来预测相对湿度。

提升决策树是一种广泛而有效的集成学习方法, XGBoost 作为一种新型提升决策树算法, 能够自动利用 CPU 的多线程进行并行运算, 可缩短时间, 提高精度。叶倩怡等^[7] 提出了一种基于 XGBoost 的优化组合模型, 用以对商业数据进行预测, 具有较好的精度和泛化能力。蒋晋文等^[8] 将 XGBoost 算法应用于制造业质量预测中, 实现了准确预测产品质量。张玄黎等^[9] 提出利用修正后的 CSI 幅度和相位信息作为指纹特征, 使用 XGBoost 构建高精度指纹库, 实现分米级的高精度室内定位。

关于事故预测, 国内外学者进行了深入研究。Sunny 等^[10] 采用喀拉拉邦 1999 年 1 月—2016 年 12 月的道路交通事故数据, 使用 Holt-Winters 模型和 ARIMA 模型进行了交通事故预测。王文博等^[11] 建立了一个基于相关向量机的交通事故时序序列预测模型, 预测效果良好, 预测精度高于灰色模型、支持向量机等经典模型。孟祥海等^[12] 构建了一组 IHSDM 事故预测改进模型对 11 类高速公路进行事故预测, 与 IHSDM 相比, 改进模型具有更高的精度和更好的适用性。Kartikya 等^[13] 分析了时间序列在印度交通量预测中的应用, 比较了研究前景与局限。孙轶轩^[14] 运用分类、回归、聚类分析、关联规则等相关理论和方法, 构建了数据挖掘的道路交通事

* 收稿日期: 2019-05-24

作者简介: 谢学斌, 教授, 博士, 从事安全评价研究, 2796939525@qq.com。

故分析体系。Sharma 等^[5]应用 ARIMA 模型预测了 2015 年的死亡人数,模型验证表明,ARIMA 的表现优于 DTES。张杰等^[6]利用 ARIMA 模型对交通事故的十万人口死亡率时间序列进行了预测。沙爱敏^[7]用灰色模型 GM(1,1) 对高速公路交通事故数量进行了预测。童飞^[8]采用三层 BP 神经网络对 7 个指标和 4 个事故类型进行了预测。蒋宏等^[9]利用时间序列和灰色模型理论对交通事故数据建立模型并进行了步长为 12 的预测。郁健等^[10]构建了基于 ELM 和 H-ELM 的交通事故预测模型。钱吴永^[11]在灰色模型的基础上对交通事故成因及趋势进行了分析。陈小波^[12]采用灰色系统事故预测模型对未来事故率进行了预测。王玮琳等^[13]利用灰色理论和关联分析进行了旅游区安全事故研究,确定了事故发生的要素。陈芳等^[14]利用 ARIMA 模型和 BP 神经网络建立了用于我国民航业的事故征候率预测模型。

时间序列中包含非平稳的不确定信息,ARIMA 模型的差分运算弱化了时间序列的随机性,实现了简便、高效的时间序列线性特征信息提取过程。但差分运算忽略了由时间序列非线性特征所导致的不确定信息。因此,本文建立基于 ARIMA 和 XGBoost 的交通事故预测模型。

1 ARIMA 模型和 XGBoost 模型

1.1 ARIMA 模型

自回归滑动平均(ARIMA)模型法由美国统计学家博克斯和英国统计学家詹金斯提出。主要思想为,将研究对象随时间推移而形成的数据序列视为一组依赖于时间 t 的随机变量,这组随机变量的相关性可以通过将过去的观测值结合随机扰动因素建立随机时间序列模型(ARIMA 模型)描述出来,并认为这种相关性也表示了未来的发展趋势,从而可以通过该模型及已有的观测值对未来值进行预测。

在 ARIMA 预测模型中,预测值表示为由最近的真实值和最近的预测误差组成的显性函数。ARIMA 主要用于拟合具有平稳性的时间序列。非平稳的时序可以通过差分来转换为平稳性时序。具体来说,差分就是将时序中的每一个观测值 Y_t 都替换为 $Y_{t-1} - Y_t$ 。

在一个 p 阶自回归模型中,序列中的每一个值都可以用它之前 p 个值的线性组合来表示,即

$$AR(p): Y_t = \mu + \beta_1 Y_{t-1} + \beta_2 Y_{t-2} + \cdots + \beta_p Y_{t-p} + \varepsilon_t \quad (1)$$

式中 Y_t 为时序中的任一观测值, μ 为序列均值, β 为权重, ε_t 为随机扰动。

在一个 q 阶移动平均模型中,时序中的每个值都可以用之前的 q 个残差的线性组合来表示,即

$$MA(q): Y_t = \mu - \theta_1 \varepsilon_{t-1} - \theta_2 \varepsilon_{t-2} - \cdots - \theta_q \varepsilon_{t-q} + \varepsilon_t \quad (2)$$

式中 ε 为预测的残差, θ 为权重。这两种方法的混合即 ARMA(p, q) 模型,其表达式为

$$Y_t = \mu + \beta_1 Y_{t-1} + \beta_2 Y_{t-2} + \cdots + \beta_p Y_{t-p} - \theta_1 \varepsilon_{t-1} - \theta_2 \varepsilon_{t-2} - \cdots - \theta_q \varepsilon_{t-q} + \varepsilon_t \quad (3)$$

此时,序列中的每个观测值用过去的 p 个观测值和 q 个残差的线性组合来表示。

ARIMA(p, d, q) 模型意味着时序被差分了 d 次,且序列中的每个观测值都是用过去的 p 个观测值和 q 个残差的线性组合表示的。

建立 ARIMA 模型的步骤: 首先确保时序是平稳的,找到 1 个(或几个)合理的模型(即选定可能的 p 和 q); 然后拟合模型,从统计假设和预测准确性等角度评估模型; 最后根据最为合理的模型进行预测。

1.2 XGBoost 模型

极端梯度提升(XGBoost)模型全称 Extreme Gradient Boosting,是一种基于决策树(CART)的分布式高效梯度提升算法。XGBoost 中最主要的基学习器为 CART(分类与回归树),基本原理如下。

第一步,给定数据集 $D = \{(X_i, y_i)\}$, 采用以下函数对样本进行预测。

$$\hat{y}_i = \phi(X_i) = \sum_{k=1}^K f_k(X_i) \quad f_k \in F \quad (4)$$

式中 $F = \{f(X) = \omega_{q(X)}\} \{q: \mathbf{R}^m \rightarrow T, \omega \in \mathbf{R}^T\}$, K 为决策树数量, F 表示决策树空间, $q(X)$ 表示将样本 X 映射到树的叶子节点,其对应叶子节点的分数为 $\omega_{q(X)}$ 。

第二步,正则化目标函数。

$$L(\phi) = \sum_i l(\hat{y}_i, y_i) + \sum_k \Omega(f_k) \quad (5)$$

式中 $\Omega(f) = \gamma T + 1/2\lambda \|w\|^2$, T 为叶子节点数,并且经过第 t 次迭代后有 $\hat{y}_i^{(t)} = \hat{y}_i^{(t-1)} + f_t(x_i)$ 。

此时目标函数为

$$L^{(t)} = \sum_{i=1}^n l(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)) + \Omega(f_t) \quad (6)$$

第三步,二阶泰勒展开,有

$$L^{(t)} = \sum_{i=1}^n [\ell(y_i, \hat{y}_i^{(t-1)}) + g f_t(X_i) + \frac{1}{2} h f_t^2(X_i)] + \Omega(f_t) \quad (7)$$

去掉常数项,有

$$\tilde{L}^{(i)} = \sum_{i=1}^n \left[g_i f_i(X_i) + \frac{1}{2} h_i f_i^2(X_i) \right] + \Omega(f_i) \quad (8)$$

第四步,优化目标函数。

$$\tilde{L}^* = -\frac{1}{2} \sum_{j=1}^T \frac{G_j^2}{H_j + \lambda} + \gamma T \quad (9)$$

式中 $G_j = \sum_{i \in I_j} g_i$, $H_j = \sum_{i \in I_j} h_i$ 。

2 基于 ARIMA 和 XGBoost 的交通事故预测模型

2.1 指标选取

交通事故分析的相关指标主要有总量指标、相对指标、平均指标、动态指标、事故率等。总量指标是反映交通事故现象在一定时间、地点、条件下的总体规模和水平,其表现形式为绝对数或绝对指标。总量指标一般按照反映时间节点意义的不同分为时期指标和时点指标,分别描述一段时期内和某一时点上规模或水平的总量,因此其数据结构适用于时间序列建模^[8]。

总量指标中最具代表性的就是交通事故 4 项指标,即“事故起数”“受伤人数”“死亡人数”和“损失”。本文选择该 4 项指标建立原始序列,分别用 $\{Y_{\text{number}}\}$ 、 $\{Y_{\text{injury}}\}$ 、 $\{Y_{\text{death}}\}$ 和 $\{Y_{\text{lost}}\}$ 表示。

本文提到的交通事故相关指标含义如下。

事故起数: 在单位时间内某地区发生的交通事故数量。

受伤人数: 在单位时间内某地区发生的交通事故导致的受伤人数。

死亡人数: 在单位时间内某地区发生的交通事故导致的死亡人数。

损失: 在单位时间内某地区发生的交通事故导致的财产损失。

单位时间可取年、季、月、日等,某地区可取全国、全省、全市等。在本文中,时间以年为单位,地区指全国范围。

2.2 交通事故预测模型的建立

对原始序列进行建模,建模过程如下。

1) 对交通事故不同指标的原始序列进行平稳性检验。首先,根据原始序列图判断其平稳性及判断是否对其进行差分,如果进行差分则对差分后的序列做 ADF 检验(单位根检验)。根据 ADF 检验结果的 p -value(假定值)选择是否再次进行差分。

2) 对差分后的序列生成自相关(ACF)和偏自相关(PACF)图,确定 ARIMA 模型类型和阶数。

3) 利用 2) 确定的 ARIMA 模型对 4 项指标进行建模,根据 AIC(赤池信息准则)值确定最优模型。同时,检验模型的残差是否满足均值为 0 的正态分布。利用确定的 ARIMA 模型对 4 项指标进行预测。

4) 根据 3) 的预测结果,构造残差序列 $\{e_{it}\}$ 。令 e_{it} 表示时间 t 处模型的残差,有

$$e_{it} = Y_{it} - \hat{y}_{it} \quad (10)$$

式中 Y_{it} 为真实值, $\hat{y}_{it}$ 为时间 t 处 ARIMA 模型的预测值。

5) 对残差序列 $\{e_{it}\}$ 建立 XGBoost 模型,用来描述残差序列中的非线性关系。XGBoost 模型输出结果为时间 t 处线性模型的残差预测值,记为 $\hat{l}_{it}$ 。

6) 根据 3) 中的模型预测值和 5) 中的残差预测值得到组合模型预测值,即

$$\hat{Y}_{it} = \hat{y}_{it} + \hat{l}_{it} \quad (11)$$

本文提出的混合模型流程见图 1。




图 1 基于 ARIMA 和 XGBoost 混合模型的流程图

Fig. 1 Flow chart based on ARIMA and XGBoost hybrid model

3 实例分析

3.1 原始序列

选取国研网(<http://www.drcnet.com.cn/www/int/>) 1951—2010 年中国交通事故统计数据作为研究对象(其中“损失”数据为 1973—2010 年的交通事故数据),以年作为时间维度构建“事故起数”“受

伤人人数”“死亡人数”和“损失”4 项指标时间序列, 分别用序列 $\{Y_{\text{number}}\}$ 、 $\{Y_{\text{injury}}\}$ 、 $\{Y_{\text{death}}\}$ 和 $\{Y_{\text{lost}}\}$ 表示, 原始数据趋势变化见图 2~5。

3.2 ARIMA 模型的建立

对原始序列进行平稳性检验, 首先根据原始序列图判断其平稳性及是否对其进行差分, 对差分后的序列做 ADF 检验。原始序列 ADF 检验结果见表 1。




图 2 “事故起数”原始序列

Fig. 2 Original sequence of “accident number”




图 3 “受伤人数”原始序列

Fig. 3 Original sequence of “injured population”




图 4 “死亡人数”原始序列

Fig. 4 Original sequence of “number of deaths”

如表 1 所示, 其中 $\{Y_{\text{number}}\}$ 、 $\{Y_{\text{injury}}\}$ 、 $\{Y_{\text{death}}\}$ 和 $\{Y_{\text{lost}}\}$ 4 个指标时间序列 p -value 均大于 0.05, 因此原始序列均为非平稳序列, 需进行差分运算。经过一阶差分和二阶差分后的 ADF 检验结果见表 2。

一阶差分后的 p -value 均大于 0.05 并进行二阶差分, 二阶差分后的 p -value 均小于 0.05, 可知二阶差分后各序列平稳, 可用于 ARIMA 建模。以“死亡人数”序列为例进行交通事故的预测说明。

首先, 对二阶差分后的“死亡人数”序列生成自相关系数(ACF)和偏自相关系数(PACF)图, 见图 6 和 7, 从而确定 ARIMA 模型类型和阶数。

根据“死亡人数”二阶差分序列的自相关系数和偏自相关系数图, 依照选择 ARIMA 模型的方法, 选取参数 p 、 d 和 q , 并根据最小信息量 AIC 原则选择 ARIMA(1, 2, 0) 为“死亡人数”序列预测的最优模型。一般来说, 如果模型合适, 模型的残差应满足均值为 0 的正态分布, 并且对于任意的滞后阶数, 残差自相关系数为 0。在正态 Q-Q 图中, 如果数据满足正态分布, 则图中的数据点大多数会落在线上, 图 8 显示“死亡人数”二阶差分序列的结果满足正态分布。通过 Box. test () 函数得出该序列 p -value 为

表 1 四项指标 ADF 检验结果

Table 1 Results of four indicators ADF test

指标	事故起数	受伤人数	死亡人数	损失
p -value	0.317 1	0.089 16	0.454 7	0.608 7

表 2 四项指标差分后的 ADF 检验结果

Table 2 ADF test results after four indicators difference

指标	Y_{number}	Y_{injury}	Y_{death}	Y_{lost}
一阶差分 p -value	0.126 5	0.366 4	0.069 09	0.250 3
二阶差分 p -value	0.01	0.01	0.01	0.019 16




图 5 “损失”原始序列

Fig. 5 Original sequence of “lost”

0.904 1,模型的残差没有通过显著性检验,可认为残差的自相关系数为 0。

其他 3 项指标最终确定的最优 ARIMA 模型分别为“事故起数”——ARIMA(0,2,2)模型,“受伤人数”——ARIMA(1,2,1)模型,“损失”——ARIMA(0,2,4)模型。

3.3 ARIMA 模型预测

1951—2010 年中国交通事故 4 项指标真实值与




图 6 “死亡人数”二阶差分的自相关系数图

Fig. 6 Autocorrelation coefficient diagram of the second-order difference of “number of deaths”




图 7 “死亡人数”二阶差分的偏自相关系数图

Fig. 7 Partial autocorrelation coefficient diagram of the second-order difference of “number of deaths”




图 8 “死亡人数”二阶差分的正态 Q-Q 图

Fig. 8 Normal Q-Q diagram of the second-order difference of “number of deaths”

ARIMA 模型预测值对比见图 9~12 (“损失”指标为 1973—2010 年的数据)。

本文采用 MAPE(平均绝对百分比误差)来评价模型所得预测值的精度,经过模型识别和优化,ARIMA 模型所得预测值的 MAPE 见表 3。从表 3 可




图 9 “事故起数”ARIMA 模型预测结果

Fig. 9 Prediction results of ARIMA model of “accident number”




图 10 “受伤人数”ARIMA 模型预测结果

Fig. 10 Prediction results of ARIMA model of “injured population”




图 11 “死亡人数”ARIMA 模型预测结果

Fig. 11 Prediction results of ARIMA model of “number of deaths”

以看出,单一的 ARIMA 模型对于“事故起数”“死亡人数”“损失”3 项指标的预测精度较好,而对于“受伤人数”,平均绝对百分比误差达到了 16.653 9%,预测精度较低。

3.4 交通事故组合模型预测

对残差序列 $\{e_{\text{number}}\}$ 、 $\{e_{\text{injury}}\}$ 、 $\{e_{\text{death}}\}$ 和 $\{e_{\text{lost}}\}$ 分别进行 XGBoost 建模,对残差进行预测,使用 R 语言平台 forecastxgb 包实现建模过程。

以“死亡人数”为例,ARIMA 模型残差的原始序列及经过 XGBoost 模型建模后的预测值见图 13,根据式(11)得到最终的预测值。

$\{Y_{\text{number}}\}$ 、 $\{Y_{\text{injury}}\}$ 、 $\{Y_{\text{death}}\}$ 和 $\{Y_{\text{lost}}\}$ 4 项指标序列的原始数据、ARIMA 模型预测值及组合模型预测值的对比见图 14~17,可以看出组合模型更接近真实值。同时使用 Holt-Winters 指数平滑模型与本

文提出的 ARIMA 模型及 ARIMA 组合模型做对比,采用 MAPE 指标说明模型的预测精度。如表 4 所示,4 项指标的组合预测模型的预测精度都优于单一的 ARIMA 模型和 Holt-Winters 模型,其中以“受伤人数”和“死亡人数”两个指标的组合改善效




图 14 “事故起数”组合模型预测结果

Fig. 14 Prediction results of combined model of “accident number”




图 15 “受伤人数”组合模型预测结果

Fig. 15 Prediction results of combined model of “injured population”




图 16 “死亡人数”组合模型预测结果

Fig. 16 Prediction results of combined model of “number of deaths”

表 3 ARIMA 模型的 MAPE

Table 3 MAPE of the ARIMA model

指标	事故起数	受伤人数	死亡人数	损失
MAPE/%	12.688 7	16.653 9	11.513 1	9.325 2




图 12 “损失”ARIMA 模型预测结果

Fig. 12 Prediction results of ARIMA model of “loss”




图 13 “死亡人数”残差对比图

Fig. 13 Residual comparison chart of “number of deaths”




图 17 “损失”组合模型预测结果

Fig. 17 Prediction results of combined model of “loss”

表 4 三种模型的 MAPE %

Table 4 MAPE of three models

	事故起数	受伤人数	死亡人数	损失
ARIMA 模型	12.688 7	16.653 9	11.513 1	9.325 2
Holt-Winters 模型	17.253 6	17.213 3	16.727 2	10.430 7
混合模型	10.127 8	11.222 2	7.887 2	8.698 0

果最为显著。

4 结 论

本文选取 1951—2010 年中国交通事故统计数据作为研究对象,根据交通事故特点,选取了交通事故中的 4 个指标,即事故起数、受伤人数、死亡人数和损失,对其进行分析预测。首先使用 ARIMA 模型对 4 项指标进行建模,得到 ARIMA 模型预测值。根据 ARIMA 模型残差中非线性模式的局限性,对预测值的残差进行 XGBoost 建模,建立了基于 ARIMA 与 XGBoost 的交通事故时间序列组合预测模型。实例结果表明,组合模型较单一的 ARIMA 模型和 Holt-winters 模型,4 项指标的预测精度都得到了一定程度的改善,其中以“受伤人数”和“死亡人数”的模型改善效果最为显著,“受伤人数”指标的平均绝对百分比误差降低了 5.431 7 个百分点,“死亡人数”指标的平均绝对百分比误差降低了 3.625 9 个百分点。虽然组合模型的预测精度有所提高,但该过程中对残差拟合的准确度还有待提高。

References(参考文献):

- [1] JAKOBSSON T. Long range forecasts of Northern Hemisphere 500 mb height fields by ARIMA models [J]. *Meteorology and Atmospheric Physics*, 1979, 28 (2/3): 149-158.
- [2] LI Rong(李榕). Analysis and ARIMA forecasting of in-

dustrial accident death rates in China [J]. *China Safety Science Journal(中国安全科学学报)*, 2010, 20(11): 56-60, 90.

- [3] GAN Xusheng(甘旭升), DUANMU Jingshun(端木京顺), GAO Jianguo(高建国), et al. Time series prediction of aviation equipment accident based on ARIMA model [J]. *China Safety Science Journal(中国安全科学学报)*, 2012, 22(3): 97-102.
- [4] SUN Yixuan(孙轶轩), SHAO Chunfu(邵春福), JI Xun(计寻), et al. Urban traffic accident time series prediction model based on combination of ARIMA and information granulation SVR [J]. *Journal of Tsinghua University: Science and Technology(清华大学学报: 自然科学版)*, 2014, 54(3): 348-353.
- [5] XU Dongwei, WANG Yongdong, JIA Limin, et al. Real-time road traffic state prediction based on ARIMA and Kalman filter [J]. *Frontiers of Information Technology & Electronic Engineering*, 2017, 18(2): 287-303.
- [6] EYMEN A, ÜMRAN K. Seasonal trend analysis and ARIMA modeling of relative humidity and wind speed time series around Yamula Dam [J]. *Meteorology and Atmospheric Physics*, 2019, 131(3): 601-612.
- [7] YE Qianyi(叶倩怡), RAO Hong(饶泓), JI Mingshu(姬名书). Sales prediction of stores based on XGBoost algorithm [J]. *Journal of Nanchang University: Natural Science(南昌大学学报: 理科版)*, 2017, 41(3): 275-281.
- [8] JIANG Jinwen(蒋晋文), LIU Weiguang(刘伟光). Application of XGBoost algorithm in manufacturing quality prediction [J]. *Intelligent Computer and Applications(智能计算机与应用)*, 2017, 7(6): 58-60.
- [9] ZHANG Xuanli(张玄黎), XIU Chundi(修春娣), WANG Yanzhao(王延昭), et al. High-precision WiFi fingerprinting indoor localization based on CSI-XGBoost [J]. *Journal of Beijing University of Aeronautics and Astronautics(北京航空航天大学学报)*, 2018, 44(12): 2536-2544.
- [10] SUNNY C M, NITHYA S, SINSHI K S, et al. Forecasting of road accident in Kerala: a case study [C] // Indian Institute of Information Technology and Management-Kerala, Center for Excellence in Data Engineering and Computational Modeling. *Proceedings of 2018 International Conference on Data Science and Engineering (ICDSE)*, Piscataway, New Jersey. New York: Institute of Electrical and Electronics Engineers, 2018: 1-5.
- [11] WANG Wenbo(王文博), CHEN Hong(陈红), WEI Lingxiang(韦凌翔). Study on method for prediction of traffic accident time series [J]. *China Safety Science Journal(中国安全科学学报)*, 2016, 26(6): 52-56.
- [12] MENG Xianghai(孟祥海), HOU Qinzong(侯芹忠), SHI Yongyi(史永义), et al. IHSDM freeway accident prediction models [J]. *Journal of Traffic and Transportation Engineering(交通运输工程学报)*, 2016, 16(1): 123-132.
- [13] KARTIKEYA J, NISHITA S, SHRINIWAS S A, et al.

- A comparative study on application of time series analysis for traffic forecasting in India: prospects and limitations [J]. *Current Science*, 2016, 110(3): 373-385.
- [14] SUN Yixuan(孙轶轩). *Traffic accident analysis based on data mining(基于数据挖掘的道路交通事故分析研究)* [D]. Beijing: Beijing Jiaotong University, 2014.
- [15] SHARMA B, SHEKHAR C. Accidental mortality in India: statistical models for forecasting [J]. *International Journal of Humanities and Social Science Invention*, 2015, 4(4): 35-45.
- [16] ZHANG Jie(张杰), LIU Xiaoming(刘小明), HE Yulong(贺玉龙), et al. Application of ARIMA model in traffic accident prediction [J]. *Journal of Beijing University of Technology(北京工业大学学报)*, 2007, 33(12): 1295-1299.
- [17] SHA Aimin(沙爱敏). *Research on the freeway traffic accidents and countermeasures(高速公路交通事故分析及预防对策研究)* [D]. Nanjing: Southeast University, 2006.
- [18] TONG Fei(童飞). *A maritime accident forecast based on BP neural network and carried out by MATLAB(基于BP神经网络的水上交通事故预测及MATLAB实现)* [D]. Wuhan: Wuhan University of Technology, 2005.
- [19] JIANG Hong(蒋宏), FANG Shouen(方守恩), CHEN Yuren(陈雨人), et al. Traffic accidents prediction based on time series and grey model [J]. *Journal of Transport Information and Safety(交通信息与安全)*, 2012, 30(4): 93-98.
- [20] YU Jian(郁健), LI Bo(李勃), CHEN Qimei(陈启美). Study on traffic accident prediction based on H-ELM [J]. *Journal of Nanjing University: Natural Science(南京大学学报: 自然科学版)*, 2018, 54(5): 896-903.
- [21] QIAN Wuyong(钱吴永). *Grey modeling technique and its application on road traffic accidents management(灰色建模技术及其在道路交通事故管理中的应用研究)* [D]. Nanjing: Nanjing University of Aeronautics and Astronautics, 2012.
- [22] CHEN Xiaobo(陈小波). *The research in safety and accident forecast model of road traffic of Beijing(北京市道路交通安全状况分析及事故预测模型研究)* [D]. Beijing: China University of Geosciences(Beijing), 2008.
- [23] WANG Weilin(王玮琳), ZHANG Hailong(张海龙). Analysis and grey prediction for the correlation degrees of the tourism scenic spots safety accidents [J]. *Journal of Safety and Environment(安全与环境学报)*, 2018, 18(6): 2115-2119.
- [24] CHEN Fang(陈芳), ZHANG Di(张迪), WEI Wei(卫微), et al. Integrated forecasting model for the civil aviation incidents rate based on the ARIMA and BP neural network [J]. *Journal of Safety and Environment(安全与环境学报)*, 2019, 19(6): 2040-2047.

On the ways to the traffic accident prediction based on the ARIMA and XGBoost combined model

XIE Xue-bin, KONG Ling-yan

(School of Resources and Safety Engineering, Central South University, Changsha 410083, China)

Abstract: The present paper intends to study and find more ways in the traffic accident prediction so as to provide data supports for traffic accident prevention. Based on the ARIMA model and the XGBoost model, the paper intends to construct a combined time series for predicting the trends of the traffic accidents related 4 indicators, that is, "the number of accidents", "the number of injured", "the number of the death casualty" and "the material loss" to be chosen and determined. According to the characteristic features of the traffic accidents, it is necessary first of all to check and determine whether the ADF test has been performed to determine the stationarity of the original sequence diagram. And, for the said determination of the stationarity of the original sequence diagram, it would be necessary to build up the ARIMA model parameters and generate an autocorrelation plot and a partial autocorrelation plot to determine the differential sequences based on the AIC values and choose the optimal model. At the same time, it is also necessary to test the model residuals to check if the differential sequences can meet the normal distribution demands, so that the sequences of the 4 indicators can be forecast and predicted by the determined ARIMA model to obtain the residual prediction values based on the predicted results and the true value by modeling the residual sequences via the XGBoost. Thus, finally, the eventually predicted value of the combined model can be derived based on the residual value predicted and the ARIMA model forecast. The case study sampling results we have gained tend to show that the prediction accuracy of the mixed forecast model of the 4 indicators tend to be excessive beyond that of the single ARIMA model and the Holt-Winters model. The model of "the injured number" and the model of "death casualty rate" can be said beyond the significant improvement effect, with the absolute average percentage error of the "injury rate" can be reduced by 5.431 7 percentage point, whereas the average absolute percentage error of the "number of the death casualty" can be reduced by 3.625 9 percentage point. Besides, the average absolute percentage error of the "number of accidents" can be reduced by 2.560 9 percentage point, while the average absolute percentage error of the "loss" can be cut down by 0.627 2 percentage point. Thus, the combined model we have proposed in this paper shall be able to provide a novel method for traffic accident prediction.

Key words: safety engineering; traffic accident prediction; time series; ARIMA; XGBoost

CLC number: X92 **Document code:** A

Article ID: 1009-6094(2021)01-0277-08